

CLASSIFICATION AUTOMATIQUE

PLACE DE MARCHÉ




SOMMAIRE

- 1) Contexte du projet
- 2) Etude de faisabilité de classification automatique
- 3) Classification supervisées des produits
- 4) Test de collecte de données



1) CONTEXTE DU PROJET



1) CONTEXTE DU PROJET

Les données :



1050 images

description

Key Features of El...

Nom image

55b85ea15a1536d46b7190ad6fff8ce7.jpg

catégorie

Home Furnishing (150)
Baby Care (150)
Watches (150)
Home Decor & Festive Needs
(150)
Kitchen & Dining (150)
Beauty and Personal Care (150)
Computers (150)

1050 lignes – 7 catégories



2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

- Pré-traitement du texte

Mots de liaison (stopwords)

Ponctuation

Fréquences, taille...

```
texte initial :  
Key Features of Elegance Polyester Multicolor Abstract Eyelet I  
texte stemmé :  
key featur eleg polyest multicolor abstract eyelet door curtain  
temps pour stemmer : 0.00836 s.  
texte lemmé :  
key feature elegance polyester multicolor abstract eyelet door  
temps pour lemmé : 2.36476 s.
```

	words	occurency	characters	contains_digit	nbr_descriptions
0	key	223	3	False	202
1	feature	404	7	False	267
2	elegance	11	8	False	6
3	polyester	68	9	False	28
4	multicolor	160	10	False	87

- +200 descriptions
- taille < 2
- chiffres

```
stop_words.update(stop_words_update)
```



2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

Méthodes basiques

- **Comptage de mot**
- **Tf-IDF**

```
input_data = ['I am rich, and the world is mine !',  
              'I will be rich, because I have to change my life.',  
              'Time is money, but money does not give you back time.']
```

Comptage de mot

	back	change	give	life	mine	money	rich	time	world
0	0	0	0	0	1	0	1	0	1
1	0	1	0	1	0	0	1	0	0
2	1	0	1	0	0	2	0	2	0

Tf-IDF

	back	change	give	life	mine	money	rich	time	world
0	0.000000	0.000000	0.000000	0.000000	0.622766	0.000000	0.47363	0.000000	0.622766
1	0.000000	0.622766	0.000000	0.622766	0.000000	0.000000	0.47363	0.000000	0.000000
2	0.316228	0.000000	0.316228	0.000000	0.000000	0.632456	0.000000	0.632456	0.000000

$$w_{x,y} = \text{tf}_{x,y} \times \log\left(\frac{N}{df_x}\right)$$






2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

Méthodes basiques

- **Comptage de mot**
- **Tf-IDF**



2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

Méthodes plongement de mots (Word Embedding)

● **Word2vec**

- **BERT**
- **USE**

Réseau peu profond

Window = 3 Skip-gram

```
input_data = ['I am rich, and the world is mine !',  
             'I will be rich, because I have to change my life.',  
             'Time is money, but money does not give you back time.']
```

Vector_size = 300 Dim([0.23, 0.04, ..., 0.78]) = (300,)

Train

Représentation vectorielle de
chaque mot dim(nb_mots, 300)

[Vecteur_mot_1
Vecteur_mot_2
Vecteur_mot_3
Vecteur_mot_4
Vecteur_mot_5
...
Vecteur_mot_nb_mots]

Moyenne pour chaque
phrase




2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

Méthodes plongement de mots (Word Embedding)

- Word2vec
- BERT
- USE

**Transformer,
Réseau profond
avec attention**



2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

Méthodes plongement de mots (Word Embedding)

- **Word2vec**
- **BERT**
- **USE**

Réseau profond

```
input_data = ['I am rich, and the world is mine !',  
             'I will be rich, because I have to change my life.',  
             'Time is money, but money does not give you back time.']
```



Représentation vectorielle de
chaque phrase : shape(512 ,)

[Vecteur_phrase_1
Vecteur_phrase_2
Vecteur_phrase_3]






2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des descriptions

Méthodes plongement de mots (Word Embedding)

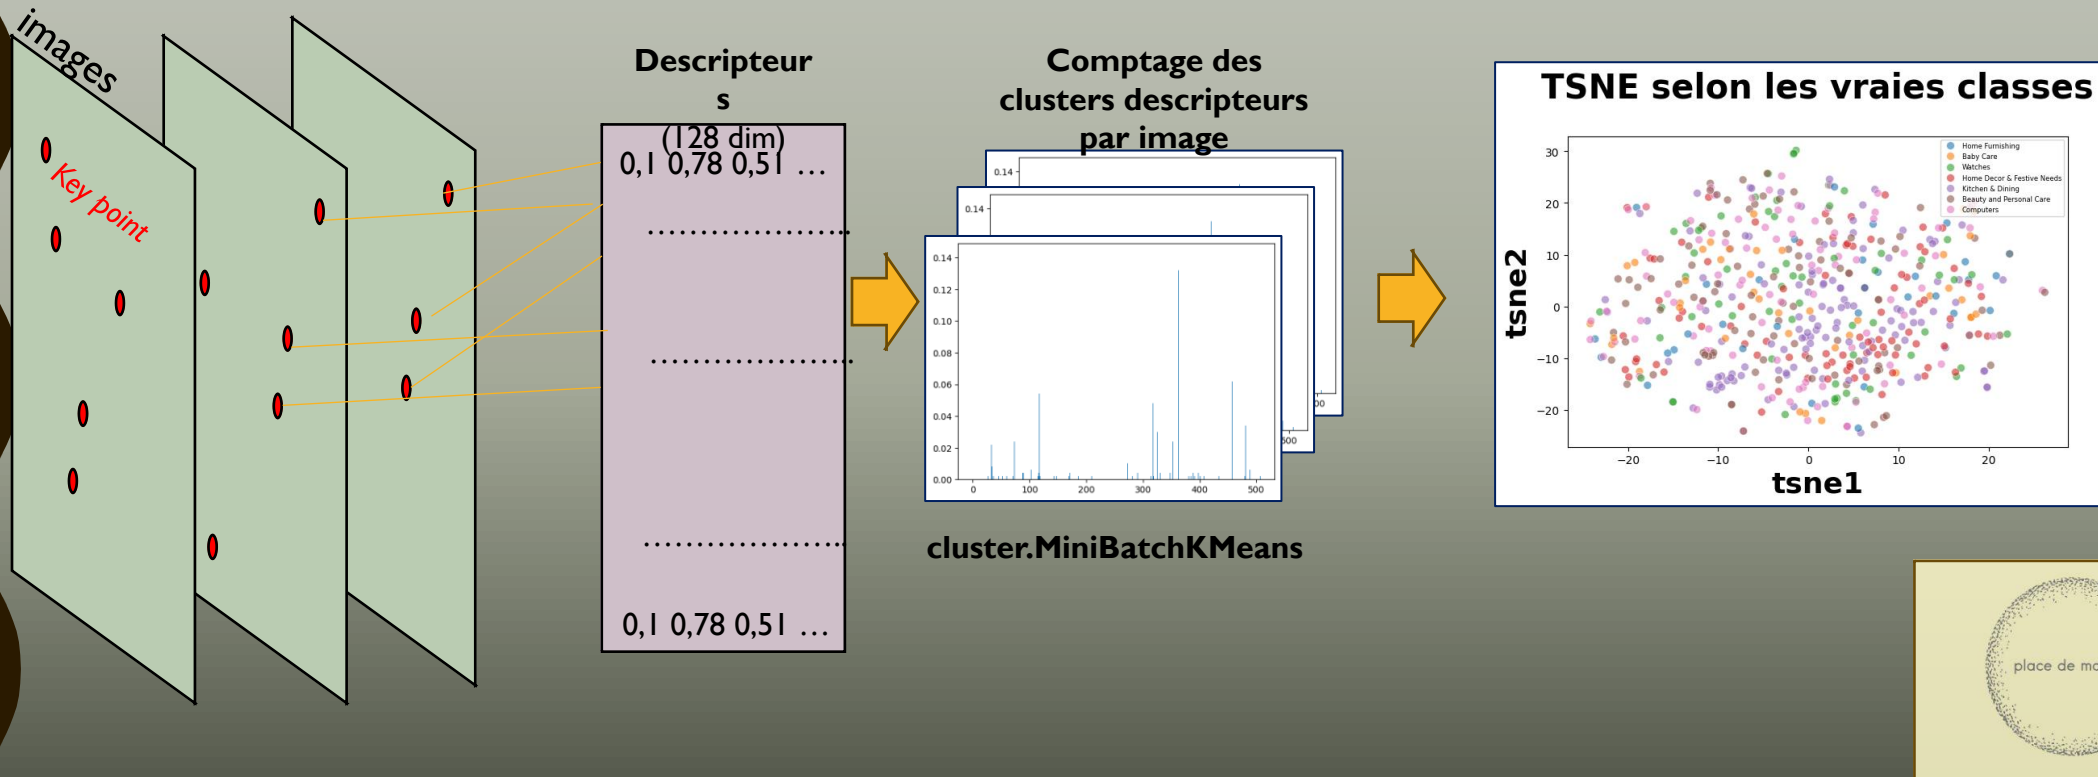
- **Word2vec**
- **BERT**
- **USE**



2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des images


- SIFT
- VGG16



2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des images

- SIFT
- VGG16



(4096,)





2) ETUDE DE FAISABILITÉ DE CLASSIFICATION AUTOMATIQUE

A partir des images



- SIFT
- VGG16

SIFT



ARI : 0.071

VGG16



ARI : 0.452



Kitchen dans
computer



3) CLASSIFICATION SUPERVISÉE DES PRODUITS

4 approches



Approche I : préparation amont des images



- Array
- Normalisation
- Reshape(224, 224, 3)

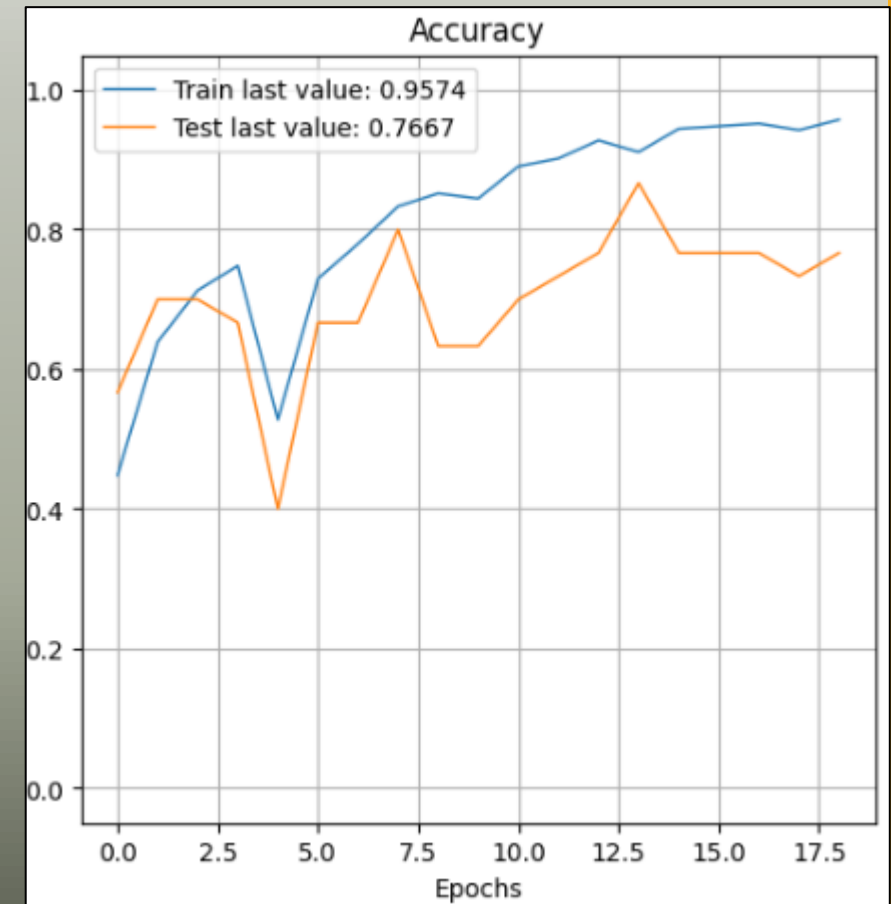
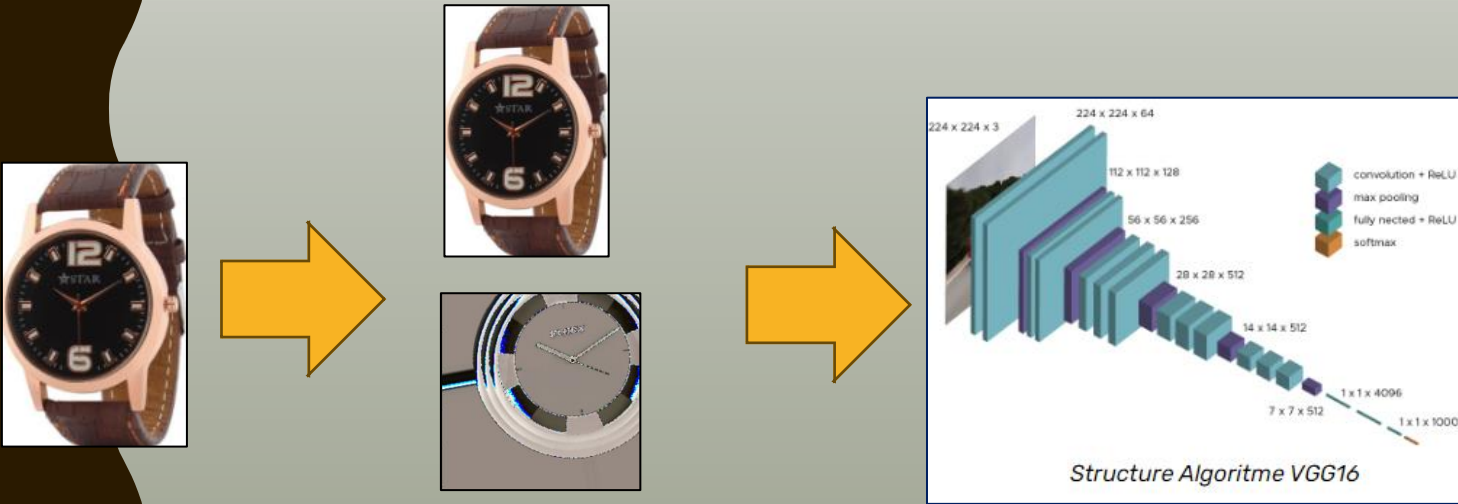
Dense(7, activation='softmax')

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}}$$





3) CLASSIFICATION SUPERVISÉE DES PRODUITS

Approche 2 : préparation amont des images et data augmentation



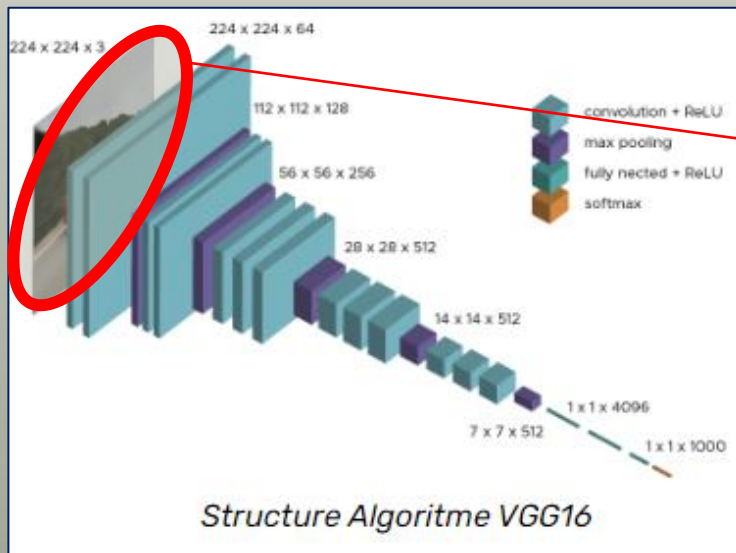
3) CLASSIFICATION SUPERVISÉE DES PRODUITS

Approche 3 : image dataset




3) CLASSIFICATION SUPERVISÉE DES PRODUITS

Approche 4 : image dataset avec data augmentation intégrée




```
model = Sequential([  
    data_augmentation,  
    Rescaling(1./127.5, offset=-1),  
    model_base,  
    GlobalAveragePooling2D(),
```



3) CLASSIFICATION SUPERVISÉE DES PRODUITS

Approche 2 : préparation amont des images et data augmentation



Evaluation accuracy test set : 0.8762



4) TEST DE COLLECTE DE DONNÉES

Rapid API Search for APIs

Edamam Food and Grocery Database By Edamam | Updated 12 days ago | Food FREEMIUM

Popularity: 9.6 / 10 Latency: 561ms Service Level: 100% Health Check: N/A

Endpoints About Tutorials Discussions Pricing Subscribed

This API provides you with tools to find nutrition and diet data for generic foods, packaged foods a [Show more...](#)

V1 (Current)

Search endpoints

Food Request Step 1 - Parser

`GET /api/food-database/v2/parser`

Food Request Step 2 - Nutrients

Test Endpoint

List of food objects, with each food object containing: kcal per 100gr, protein per 100 grams, carbohydrates per 100 grams, brand of the food, if the food is generic or brandid, a list of existing measures for the food, contents label of the food

The parser access point handles text search for foods as well as filters for the foods like presence specific nutrient content or exclusion of allergens.

- Search for a phrase or keyword using NLP to get food entities from it.

Code Snippets Example Responses Results

(Node.js) Axios [Copy Code](#)

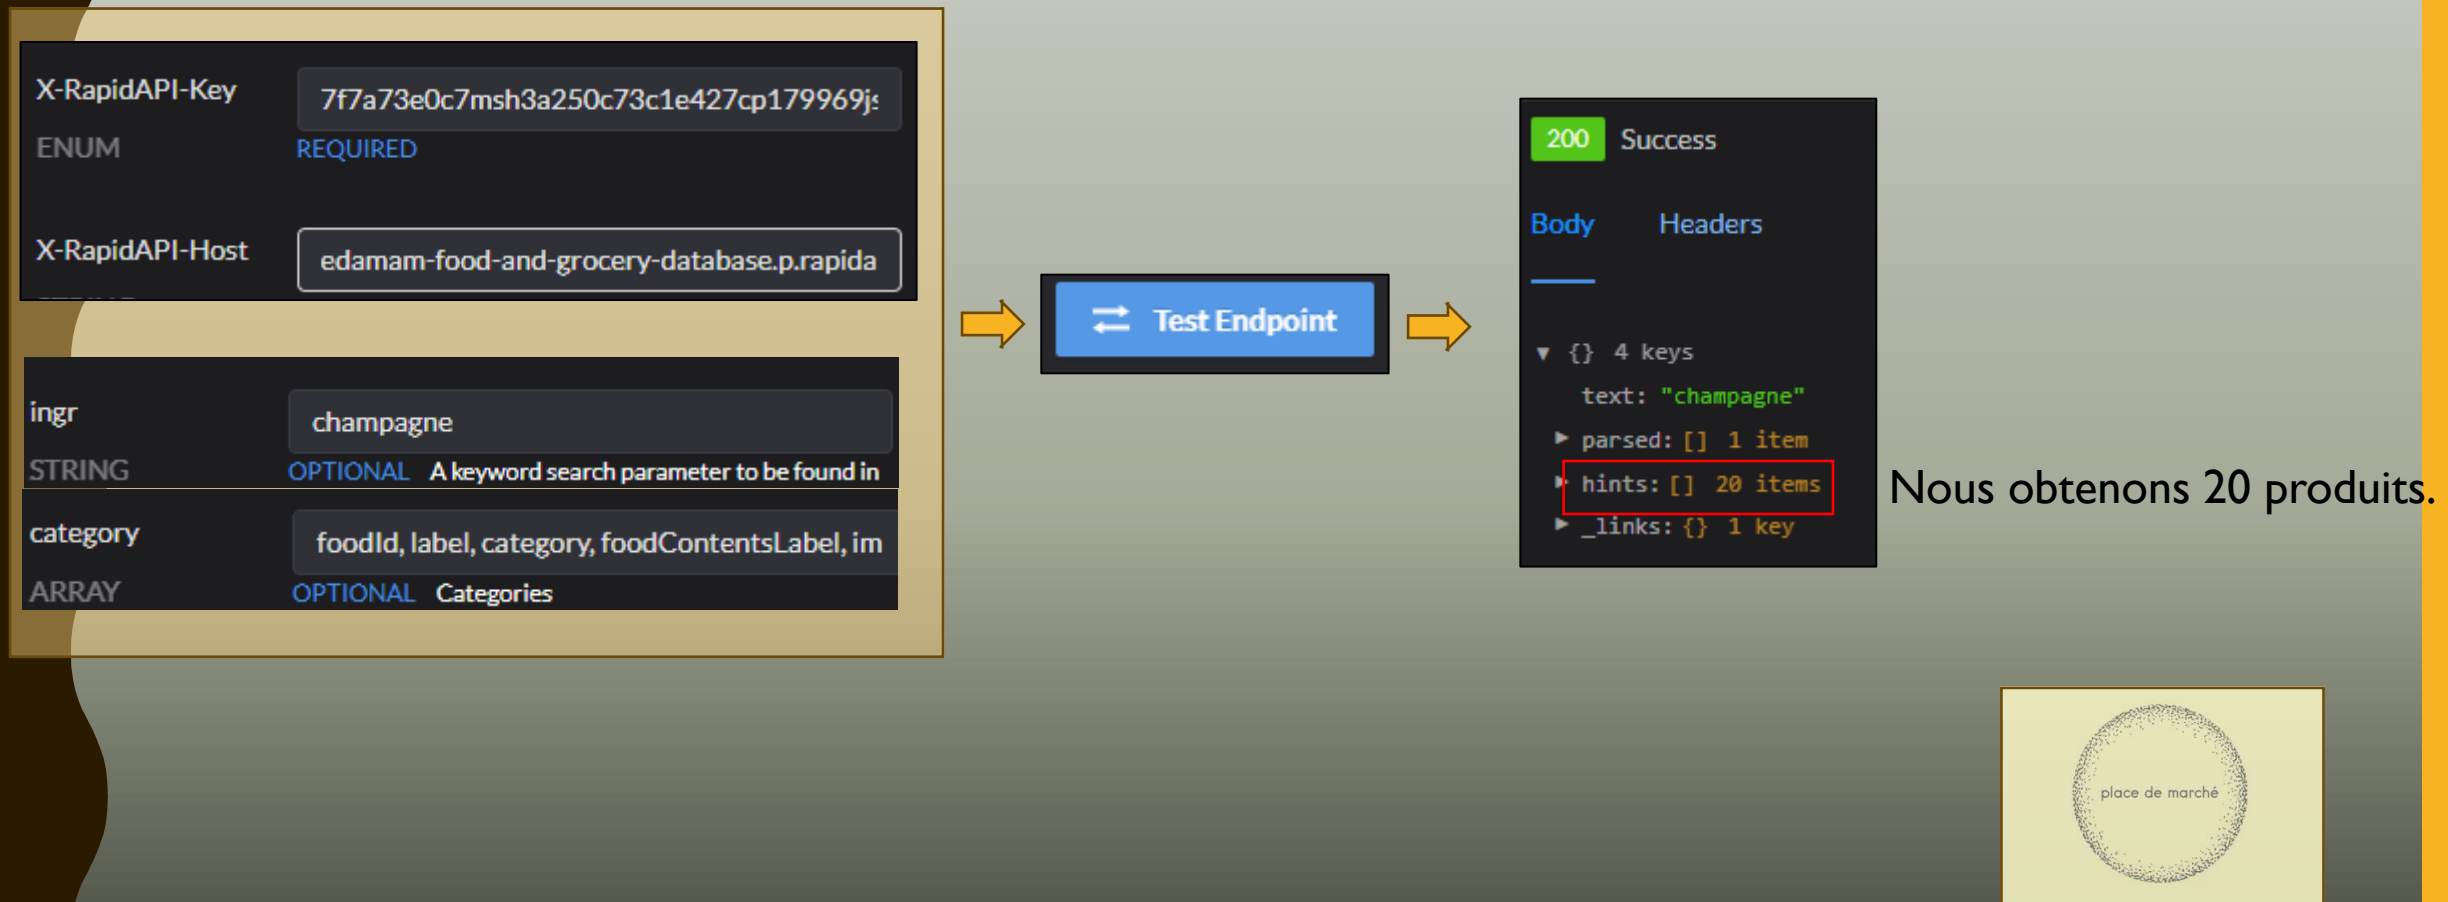
```
const axios = require('axios');

const options = {
  method: 'GET',
  url: 'https://edamam-food-and-grocery-database.p.rapidapi.com/api/food-database/v2/parser'.
```

Clés API, paramètres

Code généré et résultat

4) TEST DE COLLECTE DE DONNÉES



FIN

Merci de votre attention

